

사람 2 기술·보안 검토서

사내 회의 지식검색용 RAG 시스템 도입안

작성자: 박서연(플랫폼/보안) | 2026-08-08

1. 결론 요약

도입 자체에는 찬성하지만, 처음부터 15,000 건 전체를 색인하는 방식에는 반대합니다. 권한 누락과 오래된 문서가 함께 들어가면 검색 품질보다 정보 노출 위험이 먼저 커질 수 있습니다. 1 차 파일럿은 최신·대표 문서 약 3,000 건으로 제한하는 편이 적절합니다.

2. 권장 아키텍처

- 문서 파서/OCR → 정제 → 토큰 → 임베딩
- BM25 키워드 검색 + Dense Vector 검색을 결합한 Hybrid Retrieval
- 상위 20 개 후보를 가져온 뒤 Reranker 로 5 개 근거만 LLM 에 전달
- 답변 생성 후 문서 ID·문단 위치를 인용으로 표시

내부 프로젝트 코드나 사람 이름처럼 정확한 문자열이 중요한 질의가 많기 때문에 Dense 검색만 쓰는 것보다 Hybrid 방식이 더 안정적일 것으로 예상합니다.

3. 보안 요구사항

- 문서 ACL 변경이 검색 인덱스에 10 분 이내 반영될 것
- 퇴사자/부서이동 계정의 접근권한 즉시 차단
- 주민번호·전화번호 등 개인정보는 임베딩 전 마스킹
- 질의·답변 로그는 90 일 보관 후 자동 삭제
- 원문 문서는 기존 저장소에 남기고 Vector DB 에는 최소 메타데이터만 저장

4. 비용·성능 추정

항목	예상치	비고
월 운영비	약 190 만원	LLM API, 임베딩, DB, 모니터링 포함
초기 색인	3,000 건	약 2 시간 내 완료 예상
p95 응답시간	3.5 초	Rerank 포함 기준
가용성 목표	99.5%	파일럿 단계

5. 주요 리스크와 대응

- 권한 메타데이터 누락 → 색인 전 ACL 검증 실패 문서는 제외

- 오래된 회의 결론이 최신 결정처럼 검색됨 → 문서 유효기간/최종수정일 가중치 반영
- PDF 스캔본 OCR 오류 → OCR confidence 가 낮은 페이지는 별도 플래그
- 비용 급증 → 사용자당 일일 질의량 및 토큰 예산 모니터링

6. 제품팀 제안과 다른 점

제품팀은 8 주 내 전체 후보 문서 약 15,000 건을 대상으로 생각하고 있으나, 저는 3,000 건으로 시작해 권한·품질을 먼저 검증해야 한다고 봅니다. 응답속도는 p95 4 초 목표에는 동의하며, 기술적으로는 3.5 초 정도가 현실적인 초기 목표입니다.